🛡️ 大型語言模型 (LLM) 專題研究與實戰成果

165 AI 智能多模態防詐騙鑑識系統

Anti-Scam Multi-Modal Forensic System based on Llama-3 4-bit QLoRA & Gemini Vision CoT

🧠 Llama-3 4-bit QLoRA

- 單張 T4 顯存優化微調
- 繁體中文 165 劇本注入
- 開源發佈至 Hugging Face

👁️ Gemini Vision 多模態

- LANCZOS 800px 壓縮
- 節省 65% 計算與 Token
- 精準辨識對話與傳票截圖

🔗 CoT 五步思維鏈鑑識

- 身分➔誘餌➔話術➔行為➔對策
- 拒絕二分法黑箱判斷
- 具備極高可解釋性

🛡️ 台灣網域智能白名單

- 三大電信與主流電商白名單
- 政府與金融官方機構
- 黃金測試達成 0% 誤判率

🎯 成果交付：Streamlit 雲端工作台 | LINE 官方防詐機器人 | 20 筆對抗基準評估 100% 準確率

🌐 雲端線上展示：**https://165-anti-scam-ai.streamlit.app** • 開源模型：**alex0647/165-anti-scam-llama3-lora**

研究背景與防詐痛點分析

台灣詐騙手法快速翻新，傳統規則庫與關鍵字比對已面臨嚴重瓶頸

⚠️ 痛點 1：同音錯字與 Emoji 對抗性繞過

- 詐團刻意使用「加賴、投貲、飆股、溦信、領取Ⓒⓘⓝⓔ」等同音異字或特殊符號。
- 傳統 Regex 與黑名單關鍵字比對機制全面失效，漏報率極高。

⚠️ 痛點 2：新型「臨櫃說謊教戰」圖文詐騙

- 詐團直接傳送圖片教導受害人：「行員問就說是房屋修繕、買車或還親友錢」。
- 詐騙行為由線上轉移至線下行員阻詐對抗，傳統文字防護完全無法偵測截圖情境。

🔍 痛點 3：傳統防護缺乏「可解釋性」與防範指引

- 傳統防毒軟體僅回傳「危險/安全」二分法，民眾不知為何受騙，容易執意轉帳。
- 缺乏心理學陷阱拆解、法規案例引用與「即時止血、官方求證」標準作業 SOP。

💡 專題核心使命：打造新一代 AI 多模態防詐智囊

- 結合 Llama-3 4-bit QLoRA 深度微調 + Gemini 3.5 視覺多模態圖文對齊。
- 引入 CoT 五步思維鏈推理與台灣在地網域白名單，實現「高檢出、零誤判、全解釋」。

系統總體六層閉環架構

從多模態輸入到終端交付的端到端可解釋性安全鑑識管線

STEP 01	STEP 02	STEP 03	STEP 04	STEP 05	STEP 06
1. 多模態輸入層 Input Layer • 文字簡訊 / 簡訊連結 • LINE/FB/社群對話截圖 • 臨櫃話術教戰圖/假公文	**2. 視覺前處理層** Vision OCR • Gemini 3.5 Flash 引擎 • LANCZOS 800px 自適應壓縮 • EXIF 旋轉自動校正	**3. 專家 RAG 知識庫** Knowledge Engine • 15 大高發犯罪套路劇本 • 觸發關鍵字加權檢索 • 台灣 165 最新法規/案例	**4. CoT 鑑識核心** Reasoning Core • 身分➔誘餌➔心理話術 • 危險行為➔綜合風險評分 • Llama-3 QLoRA 微調大腦	**5. 防誤判結構守衛** Guardrails & Whitelist • Pydantic 結構化 Schema • 台灣三大電信/電商白名單 • 雙軌交叉驗證機制 (0% FPR)	**6. 終端交付與展示** Delivery Layer • Streamlit Cloud 互動工作台 • LINE Bot 官方通訊機器人 • CLI 終端指令與批次測試

PROJECT HIGHLIGHT | MODEL FINE-TUNING

4-bit QLoRA 大模型微調技術實踐

使用 Unsloth + PEFT 在單張 T4 GPU 上完成 Llama-3-8B 繁體中文防詐專用模型訓練

⚡ 1. 基底模型與 4-bit NF4 量化

- 基底：Meta-Llama-3-8B-Instruct 大語言模型。
- 量化：BitsAndBytes 4-bit NF4 量化，將顯存需求由 32GB 降至 8GB。
- 加速：採用 Unsloth 核心優化，微調速度提升 2.2 倍。

📊 2. 結構化防詐資料集工程

- 格式：採 ShareGPT / Alpaca 繁體中文多輪 CoT 標註對話。
- 領域語料：涵蓋 165 歷史通報、Dcard/PTT 詐騙求助貼文與反制話術。
- 負樣本注入：納入正規銀行、電商與電信促銷，避免模型過度警覺。

⚙️ 3. LoRA 超參數與收斂曲線

- 參數：r = 16, lora_alpha = 16, target_modules = [q, k, v, o, gate, up, down]。
- 學習率：2e-4 (Cosine 排程) + AdamW 8-bit 優化器。
- 訓練成果：Loss 從初始 1.85 順利收斂至 0.42，模型具備深厚台式詐騙語意感知。

🚀 4. 權重發佈與邊緣端相容性

- 開源發佈：微調 LoRA 權重已上傳至 Hugging Face 開源社群：
  👉 alex0647/165-anti-scam-llama3-lora
- 輕量適配：僅 160MB LoRA 適配器即可快速熱插拔加載至各種推理引擎。

PROJECT HIGHLIGHT | REASONING ENGINE

CoT 五步思維鏈鑑識核心

模擬 165 鑑識專家思維模式，拒絕黑箱二分法，提供具高度可解釋性之審查流程

01

Step 1: 發送者身分審查

Identity Verification

檢驗是否假冒公家機關 (地檢署/警察局)、銀行客服、網購平台或偽造海外電話號碼 (+886/境外IP)。

02

Step 2: 誘餌與威脅分析

Bait & Threat Analysis

辨識「高額獲利保證、飆股內線、帳戶即將凍結、包裹未領取、健保卡被盜用」等情感鉤子。

03

Step 3: 心理操控技巧拆解

Psychological Tactics

標記「製造時間急迫感 (限時處理)、權威施壓 (偵查不公開)、群體跟風 (投資群暗樁)、臨櫃說謊教戰」。

04

Step 4: 危險行為與金流辨識

Dangerous Action & Flow

鎖定「要求私下加 LINE、索取 OTP 驗證碼、轉帳至人頭帳戶、購買點數卡、相約面交現鈔」等危險動態。

05

Step 5: 綜合風險評估與對策

Risk Rating & Actionable Plan

輸出量化風險值 (0~100 分)，生成包含「即時止血步驟、165 官方查證指引、報案保全證據」之結構化建議。

PROJECT HIGHLIGHT | MULTI-MODAL FORENSICS

多模態截圖鑑識與視覺 OCR 前處理

解決現代詐團由純文字轉向「LINE/FB 圖片對話、臨櫃教戰圖、假傳票」之攻擊痛點

🖼️ 1. 影像前處理管線

• LANCZOS 800px 自適應縮放：
將長圖/高解析截圖等比壓制於 800px，既保留對話清晰度又降低 65% Token 消耗。

• EXIF 旋轉自動校正：
消除手機拍照上傳的 90°/180° 翻轉問題。

• RGB 模式自動規範化：
支援 PNG / JPG / WEBP 等多種格式。

👁️ 2. 視覺圖文對齊引擎

• Gemini 3.5 Flash 多模態解析：
具備超高 OCR 精準度與上下文場景語意理解力。

• 臨櫃話術教戰圖秒級識別：
精準抓出教受害人謊稱「裝潢款/親戚借款」之惡意意圖。

• 假檢警公文傳票印信比對：
辨識法務部/地檢署偽造章戳與詐騙字樣。

⚡ 3. 效能與實戰收益

• 鑑識延遲優化：
端到端圖文鑑識平均僅需 1.8 秒，符合通訊軟體即時防護需求。

• 零遺漏防護：
針對文字隱藏在圖片中的新型詐騙手法，達成 100% 召回率。

• 結構化輸出：
自動將圖片內文與對話角色映射為 Pydantic 鑑識報告。

PROJECT HIGHLIGHT | FALSE-POSITIVE GUARDRAILS

智能白名單與防誤判守衛機制

杜絕「狼來了」效應：建立台灣在地電信、電商與金融網域雙軌校驗體系

⚠️ 防詐 AI 的致命痛點：過度敏感 (False Positive Rate 居高不下)

一般 LLM 只要看到「短網址、促銷折扣、點擊領取優惠券」，便容易誤判為惡意釣魚。若頻繁誤報正常的「電信帳單」或「蝦皮/momo 折扣碼」，使用者將失去信任並關閉防護。

📡 台灣三大電信官方網域

- 中華電信：cht.tw
- 台灣大哥大：twm.tw
- 遠傳電信：fet.tw

📌 處理：正常帳單催繳、續約與官方優惠簡訊精準放行。

🛒 主流電商與生活服務

- 蝦皮購物：sho.pe
- momo 購物網：momo.dm
- PChome：pchome.tw

📌 處理：折價券領取、免運通知、物流到貨通知安全辨識。

🏛️ 政府金融與防詐機構

- 政府機關：*.gov.tw
- 教育學術：*.edu.tw
- 公私立銀行：正規網址清單

📌 處理：報稅通知、學籍註冊、銀行刷卡 OTP 交叉比對。

165 專家防詐知識庫與檢索增強 (RAG)

收錄 15 大高發犯罪套路特徵庫，動態注入 CoT 鑑識上下文

15 大台灣高發詐騙手法全覆蓋

1. 假投資理財 / 殺豬盤 / 飆股群組
2. 假冒公務機構 (地檢署/警察局/健保局)
3. 解除分期付款 / 誤設經銷商扣款
4. 假網拍交易 / 二手買賣假買家
5. 假愛情交友 / 跨國軍官受困
6. 假求職兼職 / 點讚刷單高薪
7. 猜猜我是誰 / 假冒親友急借錢
8. 假催繳罰鍰 / 逾期水電交通罰單
9. 釣魚簡訊 / 假包裹配送未取
10. 虛擬貨幣假交易所 / OTC 假幣商
11. 假中獎通知 / 抽中 iPhone 假手續費
12. 臨櫃說謊教戰 / 詐團話術教戰圖

知識庫三維結構化標籤

- 犯罪套路劇本 (Pattern & Workflow)
- 觸發關鍵字庫 (Trigger Keywords & Alias)
- 金流與行為特徵 (Money Flow & OTP Action)
- 相關法規與罪名 (刑法 339-4 加重詐欺罪)

三維即時防護處置 SOP

1. 即時止血：立即掛斷、封鎖好友、切勿提供 OTP / 網銀密碼。
2. 官方求證：撥打 165 反詐專線或利用銀行官方電話求證。
3. 證據保全：完整截圖對話紀錄、匯款單據與人頭帳號。

黃金基準測試量化評估與學術依據

20 筆對抗測試集實機量測，融合 Nielsen HCI 響應法則、資安零漏報與 0% FPR 準則

20 / 20
評估測試案例數
(涵蓋 15 大套路)

< 2.8s
P95 鑑識推播延遲
(Nielsen HCI 3s 法則)

100%
詐騙召回率 Recall
(資安零漏報原則)

0.0%
誤判率 FPR
(消除警示疲勞效應)

📋 測試集分布與實測驗證成果

- 🔴 重度危險 (高風險詐騙)：10 筆 ➔ 10/10 正確檢出 (100%)
  涵蓋：假檢警公文、殺豬盤飆股、解除分期付款、假網拍買家。
- 🟡 疑似誘騙 (中度釣魚)：3 筆 ➔ 3/3 正確預警 (100%)
  涵蓋：短網址釣魚、不明好友借款、假中獎引導加賴。
- 🟢 安全放行 (正常訊號)：7 筆 ➔ 7/7 正確判定 (100%)
  涵蓋：電信帳單、蝦皮促銷、銀行刷卡通知、好友聚餐借款。

🔬 學術標準與對抗擾動驗證 (Scientific Rigor)

- 響應時間依據：端到端平均 2.1s (P95=2.8s)，嚴格符合 NNGroup HCI 2~3s 對話心理等待極限，並於衝動期阻斷釣魚點擊。
- 資安零漏報依據：在嚴格同音錯字擾動 (「加賴、投貸、ⓛⓘⓝⓔ」) 下依然達成 100% 召回率。
- 0% 誤判率依據：解決資安界「狼來了警示疲勞」，台灣大哥大 twm.tw 與蝦皮 sho.pe 促銷短網址零誤判。

多端雲端部署與展示平台

支援 Streamlit 互動儀表板與 LINE 官方即時通訊機器人，達成跨端無縫體驗

💻 1. Streamlit 互動工作台

• 雲端網址：
https://165-anti-scam-ai.streamlit.app

• 功能亮點：
- 即時風險量化儀表盤 (0~100 分)
- 五維雷達圖與心理陷阱標籤
- 快速載入 20 筆黃金測試案例
- 支援文字貼上與多模態截圖上傳
- 結構化 JSON 鑑識報告匯出

📱 2. LINE 官方防詐機器人

• 雲端架構與整合：
- Render 雲端 24/7 全天候託管
- FastAPI + Uvicorn 異步 Webhook
- 永久固定 HTTPS 連線

• 使用者體驗：
- 長輩一鍵轉傳可疑簡訊或話術
- < 3 秒推播 165 風險鑑識卡片
- 提供三步驟即時避險行動指引

🛠️ 3. 本地開發與 CI/CD 自動化

• 一鍵自動化生態：
- 啟動網頁介面.bat
- 啟動LINE機器人.bat / ngrok.bat
- 一鍵推送到GitHub.bat

• GitHub CI/CD 持續交付：
代碼推送後自動觸發 Streamlit 與 Render 雲端重新建置，零停機熱更新。

專題核心亮點與創新價值

從演算法創新、工程架構到社會防護價值的全面突破

🚀 1. 端到端完整工程閉環

不只是 Prompt 工程：由 4-bit QLoRA 領域微調、Gemini 多模態視覺 OCR、165 劇本知識庫 RAG、Pydantic 防護守衛，到 Streamlit 雲端與 LINE 機器人上線，打造出可立即商用落地的完整軟體系統。

🔍 2. 領先的可解釋性 CoT 推理

擺脫傳統二分法黑盒子：以五步思維鏈逐步拆解身分真偽、心理誘餌、話術陷阱與危險金流，給予民眾高度可信、有理有據的心理防護與法律救濟指引。

🛡️ 3. 實戰級在地網域防誤判體系

獨創台灣電信/電商/金融白名單機制：成功解決業界防詐 AI 最頭痛的「短網址誤判問題」，在嚴格的黃金基準測試中達成 0% 誤判率 (0% FPR)，真正具備日常實用性。

🌐 4. 普惠科技與開源社群貢獻

將核心 Llama-3 微調權重開源發佈至 Hugging Face，提供跨平台 LINE Bot 讓長輩與一般民眾零門檻使用，以 AI 力量實質降低台灣民眾財產受詐風險。

🔮 FUTURE ROADMAP & CONCLUSION

未來展望與問答 (Future Roadmap & Q&A)

🎙️ 1. 語音通話 Deepfake 活體防偽

- 擴展至音訊多模態鑑識
- 即時偵測 AI 變聲詐騙
- 結合電話端即時轉錄與語意 CoT 鑑識

🤖 2. 主動反釣魚 AI 誘餌

- 部署 Autonomous Agent 扮演受害人
- 主動與詐團周旋拖延時間
- 自動套取人頭帳戶與虛擬幣錢包地址

📱 3. NPU 邊緣離線端側部署

- 將 4-bit 模型適配至手機端 NPU 晶片
- 實現無網路環境離線秒級鑑識
- 確保民眾通訊隱私 100% 不外洩

🛡️ 感謝各位教授與評審委員的聆聽！

線上體驗：**https://165-anti-scam-ai.streamlit.app** • 開源模型：**alex0647/165-anti-scam-llama3-lora**

誠摯歡迎提問與指導 (Q&A)