🛡️ 大型語言模型 (LLM) 專題研究與實戰成果

165 AI 智能多模態防詐騙鑑識系統

Anti-Scam Multi-Modal Forensic System based on Llama-3 4-bit QLoRA, Gemini Vision & Local RapidOCR

🧠 Llama-3 4-bit QLoRA

- 單張 T4 顯存優化微調
- 繁體中文 165 劇本注入
- 開源發佈至 Hugging Face

👁️ 三層式高可用視覺 OCR

- Gemini Vision 多模型切換
- 內建本地 RapidOCR 零配額限制
- 永不發生 HTTP 429/503 中斷

🔗 CoT 五步思維鏈鑑識

- 身分➔誘餌➔話術➔行為➔對策
- 識破斜線路徑偽裝與木馬簡訊
- 具備極高可解釋性

🛡️ 180+ 網域白名單與轉址

- 180+ 政府/金融/人壽/電信白名單
- 實時短網址 301/302 落地追蹤
- 黃金測試達成 0% 誤判率

🎯 成果交付：Streamlit 雲端工作台 | LINE 支援文字與截圖機器人 (@325readm) | 20 筆基準評估 100% 準確率

🌐 雲端線上展示：**https://165-anti-scam-ai.streamlit.app** • **LINE 好友連結：https://line.me/R/ti/p/@325readm**

研究背景與新型態防詐痛點分析

台灣詐騙手法快速翻新，從同音變形字、短網址路徑偽裝到木馬病毒簡訊全面演化

⚠️ 痛點 1：變形字繞過、短網址偽裝與木馬跳板

- 詐團使用「加下我 L1ne、投貲」變形字規避電信過濾，或以「t.ly/mvdis.gov.tw」斜線路徑偽裝假冒政府監理站。
- 更利用已停用之公開短網址 (goo.gl) 偽冒黑貓簽收單與聚會照片，植入 APK 木馬盜刷小額付費。

⚠️ 痛點 2：新型「臨櫃說謊教戰」與「比賽投票盜號」截圖

- 詐團傳送截圖教導被害人：「行員問就說是裝潢款」，或盜用親友帳號傳送「小朋友繪畫比賽幫投14號 (.top/.vip 網址)」。
- 傳統純文字防詐工具無法讀取對話截圖，且單一雲端 OCR 容易因免費配額耗盡 (HTTP 429) 而失效。

🔍 痛點 3：傳統防護缺乏「可解釋性」與官方短網址誤判

- 傳統防毒僅回傳「危險/安全」，民眾不知破綻在哪；同時常將合法企業短網址（如台哥大 twm5g.co、法國巴黎人壽 cardif.com.tw）誤判為高風險。
- 缺乏心理戰術拆解與即時止血、關閉電信小額付費之標準作業 SOP。

💡 專題核心使命：打造高可用 AI 多模態防詐智囊

- 結合 Llama-3 4-bit QLoRA + 三層式高可用視覺 OCR (Gemini Vision + 本地 RapidOCR + 雲端備援)。
- 引入 CoT 五步思維鏈與 180+ 台灣官方網域白名單暨實時轉址追蹤，實現「高檢出、零誤判、永不掉線」。

系統總體六層閉環架構

從多模態圖文輸入、三層式 OCR、實時短網址展開到終端交付的端到端安全鑑識管線

STEP 01

1. 多模態輸入層

Input Layer

- 可疑簡訊 / 短網址連結
- LINE/iMessage 對話截圖
- 臨櫃教戰圖 / 投票拉票圖

STEP 02

2. 三層視覺 OCR

3-Tier Vision OCR

- Gemini 2.0/2.5 多模型
- 本地 RapidOCR (零配額限制)
- LANCZOS 壓縮與雲端備援

STEP 03

3. 165 RAG 知識庫

Knowledge Engine

- 15+ 高發犯罪套路劇本
- 涵蓋木馬簡訊/iMessage 引流
- 觸發關鍵字與變形字檢索

STEP 04

4. CoT 鑑識核心

Reasoning Core

- 身分➔網域➔話術➔行為
- 實時短網址 301/302 追蹤
- 識破斜線路徑偽裝陷阱

STEP 05

5. 防誤判結構守衛

Guardrails & Whitelist

- Pydantic 結構化 Schema
- 180+ 台灣官方網域白名單
- 封鎖公開短網址 (goo.gl/t.ly)

STEP 06

6. 終端交付與展示

Delivery Layer

- Streamlit 狀態持久化工作台
- LINE Bot 支援圖片與文字
- CLI 終端與 20 筆基準測試

4-bit QLoRA 大模型微調技術實踐

使用 Unsloth + PEFT 在單張 T4 GPU 上完成 Llama-3-8B 繁體中文防詐專用模型訓練

⚡ 1. 基底模型與 4-bit NF4 量化

- 基底：Meta-Llama-3-8B-Instruct 大語言模型。
- 量化：BitsAndBytes 4-bit NF4 量化，將顯存需求由 32GB 降至 8GB。
- 加速：採用 Unsloth 核心優化，微調速度提升 2.2 倍。

📊 2. 結構化防詐資料集工程

- 格式：採 ShareGPT / Alpaca 繁體中文多輪 CoT 標註對話。
- 領域語料：涵蓋 165 歷史通報、Dcard/PTT 詐騙求助貼文與反制話術。
- 負樣本注入：納入正規銀行、人壽保單、電商與電信促銷，避免過度警覺。

⚙️ 3. LoRA 超參數與收斂曲線

- 參數：r = 16, lora_alpha = 16, target_modules = [q, k, v, o, gate, up, down]。
- 學習率：2e-4 (Cosine 排程) + AdamW 8-bit 優化器。
- 訓練成果：Loss 從初始 1.85 順利收斂至 0.42，模型具備深厚台式詐騙語意感知。

🚀 4. 權重發佈與邊緣端相容性

- 開源發佈：微調 LoRA 權重已上傳至 Hugging Face 開源社群：
  👉 alex0647/165-anti-scam-llama3-lora
- 輕量適配：僅 160MB LoRA 適配器即可快速熱插拔加載至各種推理引擎。

PROJECT HIGHLIGHT | REASONING ENGINE

CoT 五步思維鏈鑑識核心与新型態破綻攔截

模擬 165 鑑識專家思維模式，精準識破短網址偽裝、iMessage 引流與木馬病毒簡訊

01

Step 1: 發送者與通道審查

Identity & Channel Check

檢驗是否冒名公家機關、銀行信貸（如永豐貸）、黑貓宅急便，或使用中國網易免費信箱 (@126.com) 群發 iMessage。

02

Step 2: 網域與短網址解構

Domain & Redirect Forensics

實時展開短網址轉址目標；識破斜線路徑偽裝 (t.ly/mvdis.gov.tw)、高風險頂級網域 (.top/.vip) 與停用縮網址 (goo.gl)。

03

Step 3: 心理操控話術拆解

Psychological Tactics

標記「親友比賽拉票人情綁架」、「裝熟認親 (你把我刪了嗎/加下我 L1ne)」、「通訊錄跳板直呼真名傳聚會照片」。

04

Step 4: 危險行為與木馬辨識

Dangerous Action & Malware

鎖定「回復 1 啟動連結解鎖」、「誘導加私人 LINE ID」、「輸入 LINE 帳密與 OTP」、「下載 APK 木馬盜刷小額付費」。

05

Step 5: 綜合風險評估與對策

Risk Rating & Actionable Plan

輸出量化風險值 (0~100 分)，生成「切勿回覆 1 / 切勿加 LINE / 關閉電信小額付費 / 回報垃圾訊息」之具體處置指引。

PROJECT HIGHLIGHT | MULTI-MODAL FORENSICS

三層式高可用視覺 OCR 與多模態截圖鑑識

結合 Gemini Vision 與本地端 RapidOCR ONNX 神經網路，徹底根治 API 配額上限 (HTTP 429)

🖼️ 1. 影像最佳化前處理

• LANCZOS 1000px 自適應縮放：
將高解析長截圖等比例壓縮並轉為輕量 JPEG，既保留網址與小字清晰度，又大幅降低傳輸延遲。

• 跨平台格式相容：
完整支援網頁拖曳上傳 (PNG / JPG / JPEG) 與 LINE 聊天室圖片訊息即時下載解析。

👁️ 2. 三層式高可用 OCR 架構

• 第一層：Gemini Vision 多模型調度
依序調用 gemini-2.0-flash、flash-lite、1.5-flash 與 2.5-flash。

• 第二層：本地端 RapidOCR 神經網路
內建 ONNX Runtime 離線 OCR 引擎，免 API Key、零配額限制 (<0.8秒)，完美免疫 HTTP 429 配額耗盡問題！

• 第三層：多語系雲端 OCR 自動備援。

⚡ 3. 實戰截圖鑑識場景

• 假親友比賽投票截圖：
秒抓圖中 t5.clsuenfd5.top 釣魚網址與「幫我投14號」盜號話術。

• iMessage 垃圾簡訊截圖：
精準讀取「永豐貸、加下我 L1ne、內部漲停票」與「回報垃圾訊息」提示。

• 木馬病毒簡訊與臨櫃教戰圖：
100% 攔截 goo.gl 假包裹簽收單與欺瞞行員教戰守則。

PROJECT HIGHLIGHT | FALSE-POSITIVE GUARDRAILS

180+ 台灣官方網域白名單與實時短網址展開核驗

杜絕「狼來了」效應：結合 TWNIC 官方網域驗證、301/302 轉址追蹤與公開短網址攔截

⚠️ 防詐 AI 的兩難挑戰：如何同時「放行合法官方短網址」並「攔截偽裝短網址」？

本系統獨創【實時 HTTP 轉址追蹤 + 180+ 合法網域白名單 + 斜線路徑偽裝檢測】：對台哥大 (twm5g.co) 自動展開確認跳轉至 oppay.tw 安全放行；對公開免洗短網址 (goo.gl / bit.ly / t.ly/mvdis.gov.tw) 則嚴格拒絕白名單豁免並重罰！

🏦 金融銀行與人壽保險 (60+)

- 30+ 金控銀行：cathaybk.com.tw、fubon.com、ctbcbank.com、esunbank.com.tw 等
- 人壽保險官網：法國巴黎人壽 (cardif.com.tw)、國泰/南山/新光/台灣人壽等

📌 保單通知與官方活動精準判為安全 (5分)。

📡 電信、電商、交通與民生 (80+)

- 四大電信與短網址：cht.tw、twm5g.co、twm.tw、oppay.tw、fet.tw
- 電商外送售票：shopee.tw、sho.pe、momo.dm、fdp.li、kktix.cc
- 民生物流：taipower.com.tw、黑貓 (t-cat.com.tw)

🏛️ TWNIC 審核網域與防偽邊界

- 台灣官方後綴：*.gov.tw、*.edu.tw、*.org.tw、*.com.tw、*.net.tw
- 嚴格邊界檢查：必須位於第一個斜線「/」之前的主機名稱結尾

📌 徹底識破 t.ly/mvdis.gov.tw 偽裝路徑！

PROJECT HIGHLIGHT | KNOWLEDGE BASE & RAG

165 專家防詐知識庫與新型態詐騙全覆蓋 (RAG)

收錄 15+ 高發犯罪套路與最新實戰變種，動態注入 CoT 鑑識上下文

台灣高發與最新實戰詐騙手法全覆蓋

1. 惡意木馬病毒簡訊 (假黑貓包裹簽收單 / 假聚會照片 + goo.gl)
2. 假冒政府監理站/水電催繳 (t.ly/mvdis.gov.tw + 回復 1 解鎖)
3. 假親友比賽拉票釣魚盜號 (小朋友繪畫比賽幫投14號 + .top)
4. iMessage 垃圾簡訊引流 (假永豐貸 / 裝熟加 L1ne / 內部漲停票)
5. 假投資理財 / 飆股群組 / 臨櫃匯款說謊教戰守則
6. 假冒公務機構 (地檢署/警察局/健保卡鎖卡監管帳戶)
7. 解除分期付款 / 偽冒知名品牌免費信箱 (@yahoo.co.jp)
8. 假求職兼職 / 騙取存摺提款卡人頭帳戶 / 資金流水代收
9. 猜猜我是誰 / 假冒親友車禍急借錢 / AI 語音換臉
10. Web3 虛擬貨幣空投釣魚 / 惡意無限授權合約

知識庫多維結構化檢索標籤

- 犯罪套路劇本 (Pattern & Attack Chain)
- 觸發關鍵字與變形字庫 (如 L1ne、投.貨、賴我)
- 網域與發信通道特徵 (.top/.vip、@126.com、goo.gl)
- 心理操控戰術標籤 (通訊錄跳板、人情綁架、時間施壓)

客製化精準防護處置 SOP

- 針對木馬簡訊：指導立即開啟飛航模式、致電電信商關閉「小額付費代收」。
- 針對 iMessage 釣魚：指導切勿回覆 1、開啟「過濾未知寄件人」並回報垃圾訊息。
- 針對親友拉票盜號：指導絕對不可輸入 LINE 帳密與簡訊 OTP 認證碼。

黃金基準測試與真實案例實測驗證

20 筆對抗測試集 + 多組真實世界新型釣魚/合法官網盲測，達成 100% 召回率與 0% 誤判率

100%
基準測試準確率
(20/20 筆完全命中)

< 1.5s
本地 OCR + 鑑識延遲
(RapidOCR 極速響應)

100%
新型釣魚攔截率
(木馬/投票/監理站/L1ne)

0.0%
合法官網誤判率
(台哥大/巴黎人壽/蝦皮)

真實新型詐騙攔截實測 (100% 檢出)

- 假親友繪畫比賽拉票 (t5.clsuenfd5.top) ➔ 96/100 極度危險
- 假監理站罰單路徑偽裝 (t.ly/mvdis.gov.tw) ➔ 96/100 極度危險
- 木馬病毒簡訊 (黑貓簽收單/聚會照片 goo.gl) ➔ 96/100 極度危險
- iMessage 假信貸/裝熟 L1ne/漲停票截圖 ➔ 95/100 極度危險
- 境外 @126.com 信箱裝熟加 LINE (q09166) ➔ 93/100 極度危險

真實合法官方網站放行實測 (0% 誤判)

- 台灣大哥大官方短網址 (https://twm5g.co/6hR3Is)：
  實時追蹤轉址至 dcb.oppay.tw ➔ 5/100 安全 (官方活動通知)
- 法國巴黎人壽官網 (https://life.cardif.com.tw/a311)：
  匹配人壽白名單與 .com.tw 官方網域 ➔ 5/100 安全
- 蝦皮購物官方免運短網址 (https://sho.pe/...) ➔ 5/100 安全

PROJECT HIGHLIGHT | CLOUD DEPLOYMENT & DEMOS

多端雲端部署與展示平台升級

Streamlit 狀態持久化互動工作台 + 支援文字與截圖鑑識之 LINE 官方防詐機器人

💻 1. Streamlit 互動工作台

• 雲端網址：
https://165-anti-scam-ai.streamlit.app

• 最新工程升級：
- Session State 狀態持久化綁定，解決範例載入與按鈕觸發刷新問題
- 內建 RapidOCR 支援離線截圖秒級解析
- 即時風險儀表盤、破綻標註與 165 知識庫即時檢索

📱 2. LINE 官方防詐機器人

• 一鍵加入好友連結：
https://line.me/R/ti/p/@325readm
(官方帳號 ID：@325readm)

• 雙模態支援 (文字 + 圖片)：
- 支援直接轉傳可疑簡訊與網址
- 支援直接傳送「對話截圖/簡訊圖片」，自動下載並執行 OCR 鑑識
- Render 雲端 24/7 全天候值守

🛠️ 3. 本地開發與 CI/CD 自動化

• 一鍵自動化工具鏈：
- 啟動網頁介面.bat
- 啟動LINE機器人.bat / ngrok.bat
- push_to_github.py 一鍵同步工具

• GitHub CI/CD 持續交付：
代碼推送後自動觸發 Streamlit Cloud 與 Render 雲端重新建置，零停機熱更新。

專題核心亮點與創新價值

從演算法創新、三層高可用視覺架構到社會防詐價值的全面突破

🚀 1. 永不掉線的三層式多模態鑑識架構

結合 Gemini Vision、本地端 RapidOCR ONNX 神經網路與雲端 OCR 備援，徹底解決免費 API 配額耗盡 (HTTP 429) 與雲端限流 (HTTP 503) 問題，確保網頁與 LINE 機器人 100% 全時可辨識截圖。

🔍 2. 深度拆解台灣最新變種詐騙手法

精準識破「t.ly/mvdis.gov.tw 斜線路徑偽裝」、「回復 1 啟動連結解鎖」、「goo.gl 木馬病毒簡訊盜刷小額付費」、「繪畫比賽拉票盜號」與「iMessage 變形字 L1ne 引流」，提供量身定做的止血對策。

🛡️ 3. 180+ 官方白名單與實時短網址展開

內建台灣政府、30+ 金控銀行、人壽保險、四大電信與主流電商共 180+ 信任網域，搭配 HTTP 轉址追蹤，在黃金基準與真實官網測試中達成 0% 誤判率 (0% FPR)。

🌐 4. 普惠科技與跨平台零門檻守護

提供免安裝 App 的 LINE 官方機器人 (@325readm，支援點擊連結或掃碼加入) 與 Streamlit 雲端工作台，並將 Llama-3 QLoRA 權重開源至 Hugging Face，實質守護全民財產安全。

🔮 FUTURE ROADMAP & CONCLUSION

未來展望與問答 (Future Roadmap & Q&A)

🎙️ 1. 語音通話 Deepfake 活體防偽

- 擴展至音訊多模態鑑識
- 即時偵測 AI 變聲與假檢警恐嚇語氣
- 結合電話端即時轉錄與語意 CoT 鑑識

🤖 2. 主動反釣魚 AI 蜜罐代理

- 部署 Autonomous Agent 扮演受害人
- 主動與詐團周旋拖延時間
- 自動套取人頭帳戶與惡意 APK 樣本

📱 3. NPU 邊緣離線端側整合

- 將 4-bit 模型與 RapidOCR 封裝至手機 NPU
- 實現無網路環境下簡訊與畫面秒級攔截
- 確保民眾通訊隱私 100% 不外洩

🛡️ 感謝各位教授與評審委員的聆聽！

線上體驗：**https://165-anti-scam-ai.streamlit.app** • LINE 機器人：**https://line.me/R/ti/p/@325readm**

誠摯歡迎提問與指導 (Q&A)